

基于卷积神经网络的产品缺陷检测

一、引言

1.研究背景与意义

如今人们都生活在大数据时代，科学技术日益快速发展，人民的物质生活越来越丰富，因此对于各类产品的质量要求也越来越高。现在厂商生产商品主要都采用了工业自动化生产线，但是由于生产线大都不能保证完美的合格率，会不可避免的生产出不符合工艺要求的次品，如何高效且准确的识别分类存在缺陷的次品是当前工业界都在关注的重点问题。

2.问题描述

表面缺陷是质量问题中最为常见的一种情况，例如纸类产品生产过程中容易出现划痕、褶皱、污点、孔洞等缺陷，金属产品容易出现刮伤、凸起、毛刺等缺陷，这些存在表面缺陷的产品对于后续的加工都将造成非常严重的影响。因此厂商在生产中常常都会加入产品质量检测环节，但是目前很多厂商仍然在使用人工劳动力进行定期抽查，但是人工检测在实际工业产品生产中存在着较多不可靠问题。

在目前的很多缺陷检测研究中，如何提高算法的准确性、实时性和鲁棒性，一直是研究者们努力的方向。深度学习则是一种本质上构建了含有隐含层的机器学习架构模型，学术界试图通过模仿人脑的神经网络连接方式来建立一个类似的学习策略，因此将这种学习策略称为神经网络。深度学习通过大规模的数据进行训练，将神经网络中的大量具有代表性的特征信息进行汇总整理，从而对样本进行分类和预测，能够有效提升分类和预测的精度。

3.相关方法综述

近年来由于工业领域现代化的快速发展，各大企业和研究机构提出了很多种非接触式的产品表面缺陷检测方法，例如：人工肉眼检测、超声波检测、工业相机图像检测等。

由于近年来深度学习算法的快速发展，分类和预测的精度也越来越高，在机器视觉领域应用的场景也越来越广泛，因此使用图像处理算法研究机器视觉在表面缺陷检测领域具有很大的现实意义。

深度学习方面，最早应用深度学习技术的领域就是图像处理，在 1989 年加

拿大多伦多大学 Yann LeCun 教授就已经和同事们提出了卷积神经网络概念 (Convolutional Neural Networks)。卷积神经网络也被称为 CNN 网络，是一种包含了卷积层神经元的深度神经网络模型。如今一个卷积神经网络架构主要包含了两个可以通过训练产生的非线性卷积层，还有两个固定的子采样层和一个全连接层，其中隐含层的数量一般来说都设置在 5 层以上。

最开始卷积神经网络只有在小规模的应用问题上有一些较好的成果，主要原因是大尺寸图像没有取得理想效果，因此计算机视觉研究领域并没有采用这种方式。到了 2012 年 10 月，Hinton 教授和他的两个学生提出了一种更深的卷积神经网络在著名的 ImageNet 问题上取得了全球最好的效果，推动了卷积神经网络在该领域的发展。

二、数据描述

1.数据概述

数据集来源于阿里云天池，是晶圆图的缺陷数据集。

晶圆图识别对于确定晶圆缺陷成因至关重要，特别是混合模式缺陷。我们在某晶圆制造厂采集了大量的晶圆图数据，这些晶圆图是通过对晶圆片上的每一个晶粒进行电学性能测试得到。但实际采集到各类型的晶圆图在数量分布上存在较大差异，为了保持各类型数据间的平衡，我们采用对抗生成网络生成了部分晶圆图。最终形成了约 38000 张的混合模式晶圆图缺陷数据集，用于识别混合模式晶圆图缺陷，并辅助晶圆制造工艺中缺陷成因的研究。

2.数据说明

["arr_0"]：混合模式晶圆图缺陷数据，0 表示空白点，1 代表通过电学测试的正常晶粒，2 代表未通过电学测试的失效晶粒。数据形状为 52×52。

["arr_1"]：混合模式晶圆图缺陷标签，采用 one-hot 编码，共 8 维，分别对应晶圆图缺陷的 8 种基本类型（单一缺陷）。

一共有四种类型的数据集，分别是：

- （1）单一类型模式；
- （2）两种缺陷混合；
- （3）三种缺陷混合；
- （4）四种缺陷混合。

三、方法介绍

卷积神经网络本研究的基本方法，在有关研究中存在大量的研究工作，本节将对其基本原理进行简单介绍。在卷积神经网络中，通过卷积、池化层的一些操作，可以从输入数据中实现特征的提取，进而实现对输入数据的分类，并且可以简化模型复杂度，降低模型的权重参数和训练时间，进而提升模型性能。

卷积神经网络的整体结构示意图如下图 3.1 所示。

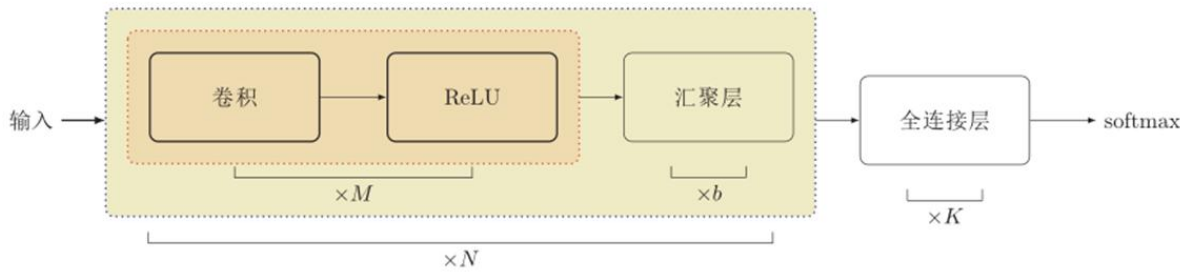


图 3.1 卷积神经网络简单示意图

1.卷积神经网络

（1）卷积层

卷积层是卷积神经网络中的一个模块，在一定程度上来说，也是最重要的模块。关于卷积操作的运算可以简化为下面的公式。可以理解为不同时间间隔下信号的衰减程度，并且随着时间的变化，信号的产生与衰减也会随之产生变化，具体如公式 3-1 所示。

$$\begin{aligned} y_t &= 1 \times x_t + 1/2 \times x_{t-1} + 1/4 \times x_{t-2} \\ &= w_1 \times x_t + w_2 \times x_{t-1} + w_3 \times x_{t-2} \\ &= \sum_{k=1}^3 w_k \cdot x_{t-k+1} \end{aligned} \tag{3-1}$$

对于二维卷积的图形化表示，如下图 3.2 所示：




图 3.2 二维卷积的示意图

因此，就需要设置新的层次结构来减少每一个特征映射的神经元的个数。研究者通常将实现这一功能的层次结构成为汇聚层（pooling layer），即“池化层”。

（2）汇聚层（池化层）

汇聚层在卷积神经网络中也是基础的模型架构之一，简单来说就是对模型的深度以及数据量进行进一步的特征提取，获取其中的关键特征。

本文以 Max 汇聚为例进行介绍，如下图 3.3 所示：




图 3.3 Max 汇聚层示意图

（3）激活函数

激活函数的意义在于能够让神经网络模型学习到更复杂的数据关系，主要是非线性变换的关系。激活函数的添加不仅是出于数理逻辑的考虑，也有借鉴生物学联结主义的成分。激活函数对神经元数据的处理可以类比生物学信号在神经元处的处理，进而将处理后的结果传递给下一层的神经元。比较常见的激活函数有：Sigmoid 函数、Tanh/双曲正切激活函数、ReLU 激活函数、softmax 激活函数。

（4）损失函数

对于深度学习模型来说，损失函数是指在训练模型的过程中，用来对训练模型的预测结果与真实标签进行对比的一个函数，并通过损失函数量化预测结果与真实标签的差距，进而选择合理的优化算法对模型的参数进行改进和“学习”。

对于分类问题来说，交叉熵损失函数更常用一些。具体见公式 3-2。

$$H(p, q) = -\sum_x (p(x) \log q(x) + (1 - p(x)) \log(1 - q(x))) \quad (3-2)$$

从计算数值的具体含义来说，交叉熵损失函数具有一定的实际意义，尤其是在具体的分类研究问题中。其刻画的是实际输出（概率）与期望输出（概率）的距离，也就是交叉熵的数值能够在一定程度上或者说在数值上反映出模型中输出结果的概率的高低或者相近程度，如果这个数值较小，那么说明两个概率分布就更加接近；反之，则说明两个概率分布就更加偏离。

2.残差网络

残差网络提出了一种残差模块连接方式，通过跳跃连接，能够有效缓解深度神经网络训练时经常出现的梯度消失问题，残差模块如图 3.4 所示。

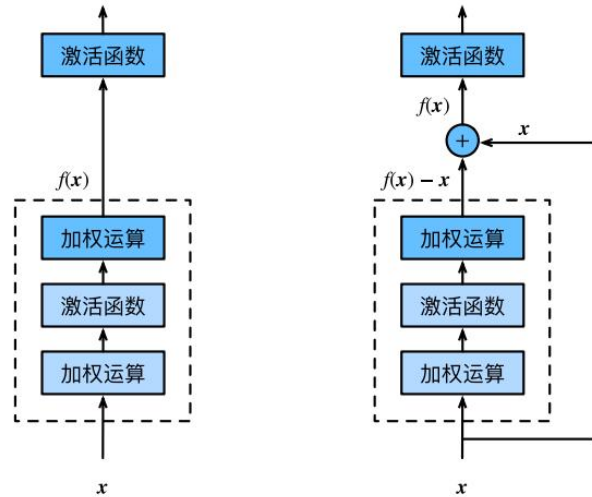


图 3.4 残差网络残差块示意图

其中 x 表示残差模块的输入， $F(x)$ 表示 x 通过卷积模块以及 relu 激活函数后的 计算值， $F(x)+x$ 表示通过将上一层没有经过计算的输入加上经过计算后的输出，求和得到的值作为下一层网络的输入，通过这种方式能够巧妙的连通上下两层卷积网络的输入输出，上一层的输入 x 的变化能够向下一直影响到最后一层残差网络，从根本上解决梯度消失问题。

3.模型评价指标

在模型训练好之后，需要将已经训练好的模型参数在测试集（或验证集）上进行测试，这是我们需要新的性能评价指标，也是衡量一个深度学习分类模型好坏的重要指标。

常用的评价指标包括：准确率、精确率、召回率与 F1 分数。其中，准确率和错误率计算公式如下：

$$(1) \text{ACC} = (\text{TP} + \text{TN}) / (\text{TP} + \text{TN} + \text{FP} + \text{FN})$$

$$(2) \text{误分类率} = (\text{FP} + \text{FN}) / (\text{TP} + \text{TN} + \text{FP} + \text{FN})$$

四、实验设计与结果

1.实验步骤

本文提出的算法采用了 `pytorch` 深度学习平台进行代码实现，输入层 `add_layer` 采用了残差网络的思想，具体步骤如下：

1) 将 4 种类型的缺陷图像进行分类，每一种缺陷都有若干张图像，图像名称按缺陷类型添加好标签准备送入网络，分辨率一致。

2) 使用 `resize` 函数对图像进行下采样降低 4 倍分辨率。

3) 将网络的输入设置为统一大小的 3 通道矩阵，设置卷积核的大小，输入层的卷积核数量为 32 个，卷积核宽度为 3，高度为 3，通过 `Conv2D` 函数进行二维卷积计算，参数 `padding` 设置为 `SAME`，经过计算映射后的图像将保持分辨率不变。

4) 使用 `BatchNormalization(BN)` 函数对二维卷积计算值进行归一化输出操作，通过这个操作可以让损失函数更加平滑，并且有利于梯度下降。

5) 在 `BN` 函数后添加 `ReLU` 激活函数，目的是为了让每一层网络都能保持梯度不为 0，能够有效抑制梯度消失问题，通过选择不同的 `ReLU` 函数可以达到不同的梯度收敛效果。

6) 将激活后的图像再次使用 `Conv2D` 函数进行二维卷积计算。

2.实验结果

设置网络的 `Batch` 为 6，`Epoch` 为 10，初始学习率为 0.1 时，发现网络学习效果较好，网络训练集的准确率在迭代次数增加时提升较快，如图 4.1 所示，训练集的 `loss` 错误率逐步递减，如图 4.2 所示。




图 4.1 模型训练准确度变化曲线


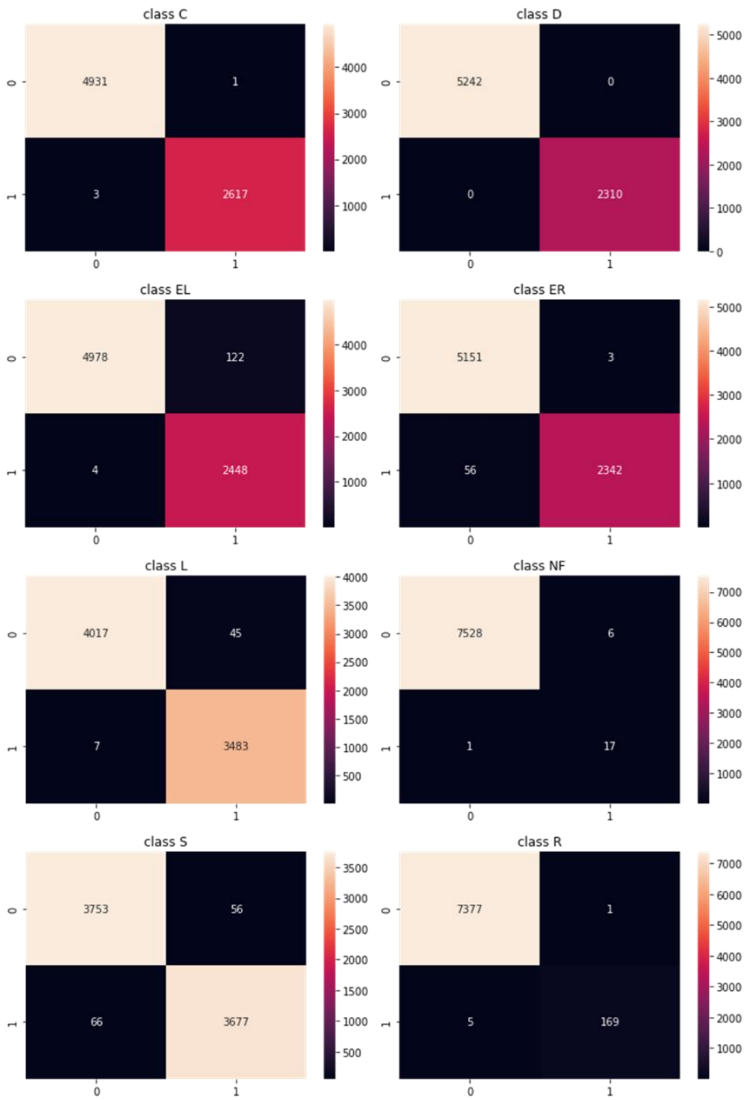


图 4.2 模型训练损失变化曲线

在数据集上的分类结果通过混淆矩阵进行展示与对比，如图 4.3 所示。由于多标签独立，我们对四种类型的数据集进行合并展示。



由图可见，在所有数据集上对 8 种缺陷类型的检测效果都比较好，基本可以达到 95% 以上，尤其是错误分辨率偏低，对实际的生产生活是比较有利的。

3. 创新点

本文基于深度学习中的卷积神经网络模型设计了一种能够有效分类多种晶圆缺陷的算法，在分类成功率上具有较高的准确性。并且，我们通过对晶圆图像数据集的处理，设计改进的残差网络 ResNet18 对数据进行训练与验证，数据结果表明该方法能够高效对晶圆缺陷检测的方法，能够在保证检测速率的同时还能达到较高的检测准确率，在实际生产过程中有着较高的实用性。